

Łódź, 14.05.2018

Zastosowanie metody iterowanej filtracji do badania zjawisk ekonomicznych na przykładzie idiosynkratycznego „efektu dźwigni”

mgr Piotr Szczepocki

Katedra Metod Statystycznych UŁ

Zebranie Katedry Ekonometrii UŁ



WYDZIAŁ
EKONOMICZNO-SOCJOLOGICZNY
Uniwersytet Łódzki



Używana w prezentacji notacja (por. Brzowska-Rup i Dawidowicz 2009):

- $x_{i:j} = (x_i, \dots, x_j)$, to realizacja procesu stochastycznego $\{X_t\}_{t \in N}$ od chwili i do j ,
- proces stochastyczny $\{X_t\}_{t \in N}$ ma wartości w przestrzeni \mathbb{R}^{n_x}
- $p(x)$ funkcja gęstość rozkładu prawdopodobieństwa zmiennej losowej X
- $p(dx)$ rozkład prawdopodobieństwa zmiennej losowej X
- $\delta: \mathbb{R} \rightarrow \mathbb{R}$ dana wzorem $\delta(x) = \begin{cases} 1 & \text{dla } x = 0 \\ 0 & \text{dla } x \neq 0 \end{cases}$,
- $\chi(A)$ indykator zbioru A

Ukryte łańcuchy Markowa – definicja (Kantas i in. 2015)

Rozważamy parę procesów stochastycznych $\{X_t, Y_t\}_{t \in \mathbb{T}}$, gdzie proces $\{X_t\}_{t \in \mathbb{T}}$ (zwany procesem stanów lub procesem ukrytym) o znanym rozkładzie początkowym $p(dx_0)$ jest procesem o funkcji przejścia (gęstości rozkładu warunkowego)

$$p(x_t | x_{t-1})$$

Proces $\{X_t\}_{t \in \mathbb{T}}$ nie jest bezpośrednio obserwowalny, tylko poprzez proces pomiaru $\{Y_t\}_{t \in \mathbb{T}}$. Zakłada się, że proces pomiaru jest warunkowo niezależny (przy danym procesie $\{X_t\}_{t \in \mathbb{T}}$) oraz posiada gęstość rozkładu warunkowego

$$p(y_t | x_t)$$

Przykładem takiej przestrzeni stanów może być para procesów $\{X_t, Y_t\}_{t \in \mathbb{T}}$ postaci

$$\begin{cases} Y_t = \Pi X_t + u_t \\ X_t = \Xi X_{t-1} + \eta_t \end{cases} \quad (1)$$

gdzie u_t i η_t są parami niezależnymi zmiennymi losowymi o rozkładzie normalnym oraz Π i Ξ są ustalonymi macierzami.

Precyzyjną formalną definicję ukrytych łańcuchów Markowa można znaleźć np. w Brzozowska-Rup i Dawidowicz (2009).

Zagadnienie filtracji

Zagadnienie filtracji polega na wyznaczeniu $p(dx_{0:t}|y_{1:t})$ rozkładu warunkowego $X_{0:t}$ pod warunkiem obserwacji $Y_{1:t} = y_{1:t}$ i $p(dx_t|y_{1:t})$ rozkładu X_t pod warunkiem obserwacji $Y_{1:t} = y_{1:t}$ oraz momentów tych rozkładów (np. wartości średniej). Ze wzoru Bayesa otrzymujemy:

$$p(x_t | y_{1:t}) = \underbrace{\frac{p(y_t | x_t)}{p(y_t | y_{1:t-1})} p(x_t | y_{1:t-1})}_{\text{korekta}} = \frac{p(y_t | x_t)}{p(y_t | y_{1:t-1})} \underbrace{\int_{R^{n_x}} p(x_t | x_{t-1}) p(x_{t-1} | y_{1:t-1}) dx_{t-1}}_{\text{predykcja}} \quad (2)$$

oraz:

$$p(x_{0:t} | y_{1:t}) = \frac{p(x_t | x_{t-1}) p(y_t | x_t)}{p(y_t | y_{1:t-1})} p(x_{0:t-1} | y_{1:t-1}) \quad (3)$$

gdzie:

$$p(y_t | y_{1:t-1}) = \int_{R^{n_x}} p(y_t | x_t) \left\{ \int_{R^{n_x}} p(x_{t-1} | y_{1:t-1}) p(x_t | x_{t-1}) dx_{t-1} \right\} dx_t$$

Podstawowy model stochastycznej zmienności (Taylor 1986):

Klasyczna postać

$$\begin{cases} y_t = \varepsilon_t \exp(h_t / 2) \\ h_t = \mu(1 - \phi) + \phi h_{t-1} + \sigma_\eta \eta_t \end{cases} \quad (4)$$

gdzie $\{y_t\}$ - zaobserwowane zwroty, $\{h_t\}$ - proces logarytmicznej zmienności, $\varepsilon_t \sim N(0,1)(iid)$, $\eta_t \sim N(0,1)(iid)$.

Dodatkowo zakłada się, że $h_0 \sim N\left(\mu, \frac{\sigma_\eta}{\sqrt{1-\phi^2}}\right)$, $|\phi| < 1$.

Parą procesów stochastycznych stanowią $\{h_t, y_t\}_{t \in \mathbb{N}}$, gdzie $\{h_t\}$ jest procesem stanów (procesem ukrytym), $\{y_t\}$ - procesem obserwowanym.

Proces ukryty jest procesem Markowa, o gęstości przejścia:

$$h_t \mid h_{t-1} = h \sim N(\mu(1 - \phi) + \phi h, \sigma_\eta^2) \quad (5)$$

Proces pomiaru ma gęstość rozkładu warunkowego:

$$y_t \mid h_t = h \sim N(0, \exp(h / 2)) \quad (6)$$

Dodatkowo zakłada się, że $h_0 \sim N\left(\mu, \frac{\sigma_\eta}{\sqrt{1-\phi^2}}\right)$, $|\phi| < 1$.

Przestrzeń stanów

Podejście
klasyczne

Uogólniona metoda momentów: Melino, Turnbull (1990)

Metoda *quasi-największej wiarygodności*, w której do oszacowania funkcji wiarygodności używa się filtra Kalmana: Harvey, Ruiz, Shephard (1994), Harvey, Shephard (1996)

Filtry cząsteczkowe (Sekuencyjne metody Monte Carlo, *Sequential Monte Carlo*):

- uczenie parametrów (*parametr learning*): Liu, West (2001), Carvalho, Johannes, Lopes, Polson (2008), Ionides, Bhadra, Atchadé, King (2011, 2015)
- Algorytm EM (*Expectation-maximization*): Kim (2005), Brzozowska-Rup i Dawidowicz (2011)

Połączenie filtra cząsteczkowego z podejściem bayesowskim:

- MCMC w ramach SMC: Gilks, Berzuini (2001)
- SMC w ramach MCMC (*Particle Markov Chain Monte Carlo*): Andrieu, Doucet, Holenstein (2010)

Podejście bayesowskie z wykorzystaniem metody MCMC (*Markov Chain Monte Carlo*): Jacquier, Polson i Rossi (1994), Kim, Shephard i Chib (1998), Pajor (2003)

Podejście
bayesowskie

Filtr cząsteczkowy (sekwencyjna metoda Monte Carlo)

- Filtry cząsteczkowe zostały opracowane niezależnie przez różnych autorów (Pitt i Shepard 1999). W szczególności Gordon i inni (1993) wykorzystali filtr cząsteczkowy do niegaussowskich modeli przestrzeni stanów, natomiast Kitagawa (1996) do modelowania szeregów czasowych. Po raz pierwszy termin filtr cząsteczkowy został użyty w pracy Del Moral (1996).
- Filtry cząsteczkowe różnią się między sobą sposobem generowania cząsteczek. Obszerne omówienie poszczególnych rodzajów filtrów cząsteczkowych można znaleźć w monografii Doucet i inni (2001), najbardziej znane to: losowanie z funkcji ważności (*Sequential Importance Sampling*, SIS), losowanie z funkcji ważności ze zwracaniem (*Sequential Importance Resampling*, SIR), filtr pomocniczy (*Auxiliary Particle Filter*)
- Filtry cząsteczkowe znalazły zastosowanie w wielu dziedzinach nauki m.in. w teorii przetwarzaniach sygnałów, chemii molekularnej, fizyce, automatyce czy ekonomii. Przegląd zastosowań można znaleźć w monografii Ristic i inni (2004).
- W ekonomii filtry cząsteczkowego wykorzystuje się m.in. w modelach stochastycznej zmienności (podstawowy, z rozkładem t-studenta, z „efektem dźwigni” i „skokami” (por. Lopez i Tsay 2011), z w modelach DSGE (Malik i Pitt 2011, Herbst i Schorfheide 2014) oraz w modelach z parametrami zmiennymi w czasie Da-Silva i in. (2011).
- Zbieżność filtru cząsteczkowego jest przedmiotem wielu prac, m.in. Del Moral (1996) wykazał zgodność, Crisan i Doucet (2002) wykazali zbieżność średniokwadratową, dowód tego twierdzenia przy słabszych założeniach można znaleźć także w Brzozowska-Rup i Dawidowicz (2009).

Filtr cząsteczkowy (sekwencyjna metoda Monte Carlo)

Filtry cząsteczkowe (zwane także sekwencyjnymi metodami Monte Carlo) są rodziną metod aproksymujących rekurencyjnie nieznaną rodzinę rozkładów warunkowych


$$p(dx_{0:t} | y_{1:t})$$

dla $t = 1, \dots, T$ poprzez kolekcję J par $(x_{0:t}^{(j)}, w_i)$, zwanych cząsteczkami. Każda cząsteczka składa się z dwóch składowych: pierwsza $x_{0:t}^{(j)}$ odpowiada punktowi z nośnika funkcji $p(x_{0:t}|y_{1:t})$, a drugą składową $w^{(j)}$ jest wagą ważności (*importance weight*).

Rozkład warunkowy $p(dx_{0:t}|y_{1:t})$ (określony na przestrzeni $\mathbb{R}^{(t+1)n_X}$) jest aproksymowany przez dyskretny rozkład empiryczny:

$$\hat{p}(dx_{0:t} | y_{1:t}) = \sum_{j=1}^J w_t^{(j)} \delta(x_{0:t} - x_{0:t}^{(j)}) \quad (7)$$

gdzie: $\{x_{0:t|t}^j\}_{j=1}^J$ jest ciągiem generowanym z odpowiednio dobranej funkcji ważności $q(\cdot)$.



Rys. 1. Przykład ilustrujący przybliżanie gęstości rozkładu ciągłego poprzez rozkład dyskretny za pomocą losowania Monte Carlo. Na rysunku przedstawiono wykres gęstości rozkładu normalnego standaryzowanego oraz 100 cząsteczek z wylosowanych z rozkładu normalnego standaryzowanego.

$$\hat{P}(X \in (-1, 1)) = \frac{1}{J} \sum_{j=1}^J \delta(x^{(j)} \in (-1, 1)) = 0,72.$$

Prawdziwa wartość $P(X \in (-1, 1)) = 0,683$.

Zauważmy, że :

$$P(X_{0:t} \in B \mid y_{1:t}) = \int_B p(x_{0:t} \mid y_{1:t}) dx_{0:t} = \int_B \frac{p(x_{0:t} \mid y_{1:t})}{q_{0:n}(x_{0:t} \mid y_{1:t})} q_{0:n}(x_{0:t} \mid y_{1:t}) dx_{0:t} \approx \frac{1}{J} \sum_{j=1}^J \tilde{w}^{(j)} \delta(x_{0:t}^{(j)} \in B), \quad \tilde{w}^{(j)} = \frac{p(x_{0:t}^{(j)} \mid y_{1:t})}{q_{0:n}(x_{0:t}^{(j)} \mid y_{1:t})} \quad (8)$$

Wagi ważności wyznacza się zatem ze wzoru:

$$\tilde{w}_t^{(j)} = \frac{p(y_t \mid x_t^{(j)}) p(x_t^{(j)} \mid x_{t-1}^{(j)}) p(x_{0:t-1}^{(j)} \mid y_{1:t-1})}{p(y_t \mid y_{1:t-1}) q(x_t^{(j)} \mid x_{0:t-1}^{(j)}, y_{1:t}) q_{0:n-1}(x_{0:t-1}^{(j)} \mid y_{1:t-1})} \propto \tilde{w}_{t-1}^{(j)} \frac{p(y_t \mid x_t^{(j)}) p(x_t^{(j)} \mid x_{t-1}^{(j)})}{q(x_t^{(j)} \mid x_{0:t-1}^{(j)}, y_{1:t})}, \quad (9) \quad w_t^{(j)} = \frac{\tilde{w}_t^{(j)}}{\sum_{j=1}^N \tilde{w}_t^{(j)}}.$$

Wynika to z równości (3):

$$p(x_{0:t} \mid y_{1:t}) = \frac{p(y_t \mid x_t) p(x_t \mid x_{t-1}) p(x_{0:t-1} \mid y_{1:t-1})}{p(y_t \mid y_{1:t-1})}$$

$$\text{Ponadto:} \quad q_{0:n}(x_{0:t}^{(j)} \mid y_{1:t}) = q(x_t^{(j)} \mid x_{0:t-1}^{(j)}, y_{1:t}) q_{0:n-1}(x_{0:t-1}^{(j)} \mid y_{1:t-1}) \quad (10)$$

$$\text{Najczęściej wykorzystuje się jako funkcję ważności funkcję przejścia: } q(x_t^{(j)} \mid x_{0:t-1}^{(j)}, y_{1:t}) = p(x_t^{(j)} \mid x_{t-1}^{(j)}). \text{ Wówczas:} \quad (11)$$

$$\frac{p(y_t \mid x_t^{(j)}) p(x_t^{(j)} \mid x_{t-1}^{(j)})}{q(x_t^{(j)} \mid x_{0:t-1}^{(j)})} = \frac{p(y_t \mid x_t^{(j)}) p(x_t^{(j)} \mid x_{t-1}^{(j)})}{p(x_t^{(j)} \mid x_{t-1}^{(j)}) p(x_{0:t-1}^{(j)} \mid y_{1:t-1})} = p(y_t \mid x_t^{(j)})$$

Uwaga: optymalny (ze względu na minimalizację warunkowej wariancji wag w chwili t) wybór funkcji ważności zaproponowali Liu i Chen (1998).

Filtr cząsteczkowy – algorytm SIR (Sequential Importance Resampling)

1. Inicjalizacja algorytmu dla $t=0$:

Dla $j = 1, \dots, J$:

Losujemy: $x_0^{(j)} \sim p(x_0)$.

Wyznaczamy wagi: $w_0^{(j)} = \frac{1}{J}$.

2. Iteracyjnie dla $t = 1, \dots, T$:

Dla $j = 1, \dots, J$:

Losujemy: $\hat{x}_t^{(j)} \sim q(x_t | x_{0:t-1}^{(j)})$


Przyjmujemy: $\hat{x}_{0:t}^{(j)} = (x_{0:t-1}^{(j)}, \hat{x}_t^{(j)})$.

Wyznaczamy wagi: $\tilde{w}_t^{(j)} = \tilde{w}_{t-1}^{(j)} p(y_t | x_t^{(j)})$.

Normalizujemy wagi: $w_t^{(j)} = \frac{\tilde{w}_t^{(j)}}{\sum_{j=1}^J \tilde{w}_t^{(j)}}$.

Losujemy (ze zwracaniem) J cząsteczek $x_t^{(j)}$ ze zbioru $\{\hat{x}_t^{(j)}, w_t^{(j)}\}$.

Przyjmujemy: $x_{0:t}^{(j)} = (x_{0:t-1}^{(j)}, x_t^{(j)})$ oraz $w_t^{(j)} = \frac{1}{J}$.



Rys. 2. Graficzna prezentacja filtru cząsteczkowego.

Źródło :<http://lia.deis.unibo.it/Research/SOMA/MobilityPrediction/filters.shtml>

Losowanie ze zwracaniem ma na celu zapobieganiu degeneracji próby, ale jednocześnie prowadzi do degeneracji różnorodności. Miarą różnorodności jest:

$$\hat{N}_{eff} = \frac{1}{\sum_{j=1}^J (w_t^{(j)})^2} \quad (1 \leq \hat{N}_{eff} \leq J).$$

Dla każdego $t = 1, \dots, T$ można otrzymać następujące oszacowania:

1. Rozkładu warunkowego $X_{0:t}$ pod warunkiem obserwacji $Y_{1:t} = y_{1:t}$:

$$\hat{p}(dx_{0:t} | y_{1:t}) = \sum_{j=1}^J w_t^{(j)} \delta(x_{0:t} - x_{0:t}^{(j)}) \quad (12)$$

2. Momentów rozkładu $X_{0:t}$ pod warunkiem obserwacji $Y_{1:t} = y_{1:t}$:

$$E(\varphi(x_{0:t}) | y_{1:t}) \approx \sum_{j=1}^J w_t^{(j)} \varphi(x_{0:t}^{(j)}) \quad (13)$$

3. Rozkładu Y_t pod warunkiem obserwacji $Y_{1:t-1} = y_{1:t-1}$:



$$\hat{p}(y_t | y_{1:t-1}) = \frac{1}{J} \sum_{j=1}^J \tilde{w}_t^{(j)} \quad (14)$$

Na podstawie całej próby można wyznaczyć oszacowanie (logarytmu) funkcji wiarygodności:

$$\hat{L}(\theta, y_1, \dots, y_T) = \prod_{t=1}^T \hat{p}(y_t | y_{1:t-1}) = \prod_{t=1}^T \left(\frac{1}{J} \sum_{j=1}^J \tilde{w}_t^{(j)} \right) \quad (15)$$


$$\ln \hat{L}(\theta, y_1, \dots, y_T) = \ln \left(\prod_{t=1}^T \hat{p}(y_t | y_{1:t-1}) \right) = \sum_{t=1}^T \ln \hat{p}(y_t | y_{1:t-1}) = \sum_{t=1}^T \ln \left(\frac{1}{J} \sum_{j=1}^J \tilde{w}_t^{(j)} \right) \quad (16)$$

Estymator funkcji wiarygodności dla dowolnego $T \geq 2$ jest nieobciążony. Estymator logarytmu funkcji wiarygodności jest obciążony.




Rys. 3. Przykład zastosowania filtra cząsteczkowego dla klasycznego modelu stochastycznej zmienności: (a góra) symulacja trajektorii logarytmicznych zwrotów, (a środek) wykres efektywnej liczby cząsteczek, (a dół) $\ln \hat{p}(y_t|y_{1:t-1})$, (b) wykres trajektorii procesu zmienności (kolor czarny) oraz średniej arytmetycznej $\hat{p}(x_t|y_{1:t})$ dla $t=1, \dots, 1000$ (kolor czerwony). Symulacja dla parametrów: $\mu=-0,5$, $\phi=0,98$, $\sigma_\eta=0,2$; $T=1000$.

(a)



(b)



Rys. 4. Przykład zastosowania filtra cząsteczkowego dla klasycznego modelu stochastycznej zmienności: (a) trajektorie 10 cząsteczek (kolor czerwony), średniej arytmetycznej $\hat{p}(x_t|y_{1:t})$ (kolor zielony), logarytmicznego procesu zmienności (kolor niebieski) dla $t=1,\dots,20$ oraz (b) empiryczne dystrybuanty rozkładu prawdopodobieństwa $p(x_{20}|y_{1:20})$ dla 10,100,1000 cząsteczek. Symulacja dla parametrów: $\mu=-0,5$, $\phi=0,98$, $\sigma_\eta=0,2$.

Filtr cząsteczkowy – estymacja parametrów

Przyjmując, że gęstości $p(x_t|x_{t-1}, \theta)$, $p(x_0, \theta)$ i $p(y_t|x_t, \theta)$ zależą od pewnego wektora parametrów θ . Wówczas:

$$L(\theta, y_1, \dots, y_T) = \prod_{t=1}^T p(y_t | y_{1:t-1}, \theta) \quad (17)$$

Trudności związane z wykorzystaniem filtru cząsteczkowego do estymacji parametrów:

- estymator (logarytmu) funkcji wiarygodności nie jest funkcją ciągłą parametrów w przypadku najczęściej stosowanych wariantów filtru cząsteczkowego (m. in. SIR, pomocniczy filtr cząsteczkowy)
- estymator logarytmu funkcji wiarygodności funkcji wiarygodności jest estymatorem obciążonym

Proponowane w literaturze metody estymacji (Kantas i in. 2015):

- Algorytm EM (*Expectation–maximization*) to iteracyjna metoda wyznaczania maksimum funkcji wiarygodności składająca się w każdej iteracji z dwóch kroków: Krok E (*Expectation*) i krok M (*Maximization*), w kroku E wykorzystuje się filtr cząsteczkowy do otrzymania symulacyjnie warunkowych wartości oczekiwanych (dla modeli SV algorytm EM został przedstawiony w Kim (2005), Brzozowska-Rup i Dawidowicz (2011))
- ciągła aproksymacja dystrybuanty empirycznej losowania ze zwracaniem zaproponowana przez Malik i Pitt (2011)
- uczenie parametrów (*parametr learning*): Liu, West (2001), Storvik (2002), Carvalho, Johannes, Lopes, Polson (2008), Ionides, Bhadra, Atchadé, King (2011, 2015)
- *Particle Markov Chain Monte Carlo*: Andrieu, Doucet, Holenstein (2010)

Uczenie parametrów (*parametr learning*):

- Liu, West (2001): metoda ta łączy (i) pomocniczy filtr cząsteczkowy, (ii) aproksymację $p(y_t | y_{1:t-1}, \theta)$ przez mieszanie rozkładów normalnych, (iii) sztucznie wprowadzoną ewolucję wektora parametrów $\theta_t = \theta_{t-1} + \varsigma_t$, gdzie $\varsigma_t \sim N(0, W_t)$

$$\hat{p}(y_t | y_{1:t-1}, \theta) = \frac{1}{J} \sum_{j=1}^J N(m^{(j)}, V; \theta_t), \quad (18)$$

$$m^{(j)} = a\theta_t^{(j)} + (1-a)\bar{\theta}_t, \quad \bar{\theta}_t = \frac{1}{J} \sum_{j=1}^J \theta_t^{(j)}, \quad V = \frac{1-a^2}{J} \sum_{j=1}^J (\theta_t^{(j)} - \bar{\theta}_t)(\theta_t^{(j)} - \bar{\theta}_t)^T$$

- Storvik (2002), Carvalho, Johannes, Lopes, Polson (2008) –modyfikacje metody Liu i Westa z wykorzystaniem statystyk dostatecznych
- Ionides i in. (2011, 2015) – iteracyjne powtarzanie filtru cząsteczkowego z parametrami wylosowanymi z wielowymiarowego rozkładu zaburzeń z malejącą z kroku na krok wariancją

Algorytm:

Niech: M – liczba iteracji, J – liczba cząsteczek, T – liczba okresów.

Dla $m=1,\dots,M$:

1. $\Theta_{0,j}^{F,m} \sim h_0(\theta | \Theta_j^{m-1}; \sigma_m)$ dla $j=1,\dots,J$

$$X_{0,j}^{F,m} \sim f_0(x_0; \Theta_j^m) \quad \text{dla } j=1,\dots,J$$

2. Dla $t=1,\dots,T$:

$$\Theta_{t,j}^{P,m} \sim h_t(\theta | \Theta_{t-1,j}^{F,m-1}; \sigma_m)$$

$$X_{t,j}^{P,m} \sim f(x_t | X_{t,j}^{F,m}; \Theta_{t,j}^{P,m}) \quad \text{dla } j=1,\dots,J$$

$$w_{t,j}^m = g(y_t | X_{t,j}^{P,m}; \Theta_{t,j}^{P,m}) \quad \text{dla } j=1,\dots,J$$

Losujemy $k_{1:J}$ wg prawdopodobieństwa: $\mathbb{P}(k_j = i) = w_{t,i}^m / \sum_{u=1}^J w_{t,u}^m$

3. Przyjmujemy: $\Theta_j^m = \Theta_{T,j}^{F,m}$ dla $j=1,\dots,J$

4. Zwiększamy $m=m+1$ i wracamy do 2.

Wkład algorytmu:

Symulator: $f_0(x_0; \theta)$

Symulator: $f(x_t | x_{t-1}; \theta)$

Ewaluator: $g(y_t | x_t; \theta)$

Dane: $y_{1:T}$

Początkowa wartość wektora

parametrów: Θ_j^0 dla $j=1,\dots,J$

Rozkład zaburzeń: $h_t(\theta | \varphi; \sigma_m)$ $t=0,1,\dots,T$

Ciąg zaburzeń: σ_m dla $m=1,\dots,M$

Wynik algorytmu:

Końcowy wektor parametrów:

$$\Theta_j^M \quad \text{dla } j=1,\dots,J$$

Zalety:

- 1) Podejście typu „plug-and-play”
- 2) Możliwość wykorzystania metody w bardzo wielu zagadnieniach
- 3) Zaimplementowane w pakiecie pomp programu R Cran
- 4) Teoretyczne własności estymatora
- 5) Dokładność estymacji porównywalna z konkurencyjnymi metodami (m.in. *PMCM*)
- 6) Klasyczne podejście „częstościowe”

Wady:

- 1) Podejście typu „plug-and-play”
- 2) Metoda aproksymuje gradient funkcji wiarygodności
- 3) „Przekleństwo wielowymiarowości”
- 4) Czas obliczeń

Twierdzenie 5 z (Ionides i in. 2011)

Niech $\{a_m\}_{m \in \mathbb{N}}$, $\{\tau_m\}_{m \in \mathbb{N}}$, $\{\sigma_m\}_{m \in \mathbb{N}}$, $\{J_m\}_{m \in \mathbb{N}}$ niech będą nieujemnymi ciągami takimi, że $\tau_m \rightarrow 0$, $\sigma_m/\tau_m \rightarrow 0$, $\sum_{m=1}^{\infty} a_m = 0$, $\sum_{m=1}^{\infty} a_m J_m \tau_m^{-2} < \infty$. Niech:

$$\hat{\theta}_{m+1} = \hat{\theta}_m + a_m \sum_{t=1}^T \left(V_{t,m}^P \right)^{-1} \left(\bar{\theta}_{t,m}^F - \bar{\theta}_{t-1,m}^F \right) \quad (19)$$

gdzie:

$$\bar{\theta}_{t,m}^F = \frac{1}{J_m} \sum_{j=1}^{J_m} \Theta_{t,j}^{F,m} \quad V_{t,m}^P = \frac{1}{J_m - 1} \sum_{j=1}^{J_m} \left(\Theta_{t,j}^{P,m} - \bar{\theta}_{t,m}^F \right) \left(\Theta_{t,j}^{P,m} - \bar{\theta}_{t,m}^F \right)^T$$

Wówczas $\lim_{m \rightarrow \infty} \hat{\theta}_m = \hat{\theta}_{MLE}$ z prawdopodobieństwem 1. Warunki te spełnione są m.in. dla $a_m = m^{-1}$, $\tau_m^2 = m^{-1}$, $\sigma_m^2 = m^{-(1+\delta)}$, $J_m = m^{(1/2+\delta)}$ (Ionides i in. 2011).

- „Efekt dźwigni” można formalnie zdefiniować jako ujemny związek pomiędzy $\mathbb{E}(h_{t+1}|y_t)$ (przyszłą zmiennością w okresie $t + 1$) oraz y_t (obecny zwrot w okresie t) (Yu 2004)
- Black (1976) zauważył, że zmienność rośnie, gdy cena aktywa spada. Zaproponował następujące wytłumaczenie zwane „efektem dźwigni”: spadek cen akcji danej spółki powoduje identyczny spadek kapitału własnego spółki; jednocześnie rynkowa cena długu pozostaje niezmienną, co powoduje wzrost współczynnika zadłużenia do kapitału własnego (*debt-to-equity ratio*) tzw. „dźwigni finansowej”
- Christie (1982) przedstawił teoretyczne uzasadnienie „efektu dźwigni” w obrębie twierdzeń Modigliani-Millera (fundamentalnych twierdzeń dotyczących finansów przedsiębiorstw)
- Hipoteza „efektu dźwigni” spotkała się liczną krytyką (Suska 2015):
 - wzrost zmienności wydaje się zazwyczaj zbyt duży, aby mógł być tłumaczony zmianą współczynnika zadłużenia do kapitału własnego
 - wzrostowi cen nie zawsze towarzyszy spadek zmienności, czasem obserwuje się nawet dodatnią zależność
 - założenie, że inwestorzy znają wartość współczynnika zadłużenia do kapitału własnego jest trudne do obronienia
 - „Efekt dźwigni” jest zazwyczaj silniejszy dla indeksów giełdowych niż pojedynczych spółek
- Alternatywnie asymetrię zmienności można tłumaczyć hipotezą sprzężenia zwrotnego zmienności (*volatility feedback effect*): jeżeli zmienność można wycenić, to oczekiwany wzrost zmienności (wzrost ryzyka) powoduje także wzrost wymaganej przez inwestorów stopy zwrotu, czyli spadek bieżącej wartości spółki (spadek ceny)

Modele stochastycznego „efektu dźwigni”:

- Bandi and Renó (2012) rozważali modele stochastycznej zmienności, w których „efekt dźwigni” zależy od procesu zmienności, model został oszacowany nieparametrycznie na podstawie danych wysokiej częstotliwości
- Yu (2012) zaproponował model stochastycznej zmienności, w którym „efekt dźwigni” zależy od znaku i wielkości zaburzeń logarytmicznych stóp zwrotu:

$$h_t = \phi h_{t-1} + \gamma \sum_{i=1}^{m+1} \left(\rho_i \varepsilon_{t-1} + \sqrt{1 - \rho_i^2} \eta_t \right) \chi(\tau_{i-1} \geq \varepsilon_{t-1} \geq \tau_i) \quad (20)$$

- Veraart i Veraart (2012) zaproponowali uogólnienia modeli stochastycznej zmienności Hestona (1993) oraz Barndorff-Nielsen i Shepharda (2001), w którym parametr ρ_t jest liniową transformacją procesu Jacobiego

$$\begin{cases} \rho_t = 2g_t - 1 \\ dg_t = (\xi - g_t)dt + \theta \sqrt{g_t(1 - g_t)} dW_t \end{cases} \quad (21)$$

- Breto (2016) zaproponował model stochastycznej zmienności, w którym parametr ρ_t jest błędzeniem losowym przekształconym odwrotną transformacją Fishera

Harvey, Ruziz i Shephard (1996) zaproponowali następujący model stochastyczny uwzględniający „efekt dźwigni”:

$$\begin{cases} y_t = \varepsilon_t \exp(h_t / 2) \\ h_{t+1} = \mu(1 - \phi) + \phi h_t + \sigma_\eta \eta_t \end{cases} \quad (22) \quad \longleftrightarrow \quad \begin{cases} y_t = \varepsilon_t \exp(h_t / 2) \\ h_{t+1} = \mu(1 - \phi) + \phi h_t + \sigma_\eta \rho y_t \exp(-h_t / 2) + \sigma_\eta \sqrt{1 - \rho^2} \xi_t \end{cases} \quad (23)$$

$$[\varepsilon_t \quad \eta]^T \sim N(0, \Sigma), \quad \Sigma = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$$

$$\xi_t = (\eta_t - \rho \varepsilon_t) / \sqrt{1 - \rho^2}, \quad [\varepsilon_t \quad \xi_t]^T \sim N(0, I_2),$$

Bretó (2014) zaproponował model idiosynkratycznego „efektu dźwigni”, w którym współczynnik asymetrii ρ_t jest procesem stochastycznym (błądzeniem losowym przekształconym odwrotną transformacją Fishera):

$$\rho_t = \frac{\exp(2g_t) - 1}{\exp(2g_t) + 1}, \quad (24)$$

$$g_{t+1} = g_t + \sigma_v \nu_t$$

$$\nu_t \sim N(0, 1)$$

Transformacja Fishera:

$$f: (-1, 1) \rightarrow R,$$

$$f(x) = \operatorname{arctanh} x = \frac{1}{2} \ln \left(\frac{1+x}{1-x} \right).$$


Odwrotna transformacja Fishera:

$$g: R \rightarrow (-1, 1),$$

$$g(x) = \tanh x = \frac{\exp(2x) - 1}{\exp(2x) + 1}$$

Tw. Fisher (1915)

Niech (X, Y) ma dwuwymiarowy rozkład normalny o parametrze korelacji ρ . Oznaczmy przez r współczynnik korelacji z próby. Wówczas $f(r)$ ma rozkład normalny o wartości oczekiwanej $f(\rho)$ i odchyleniu standardowym równym $\frac{1}{\sqrt{N-3}}$, gdzie f jest transformacją Fishera.



Rys. 5. Transformacja Fishera i odwrotna transformacja Fishera.

Źródło: opracowanie własne przy użyciu programu R Cran.

Idiosynkratyczny „efekt dźwigni”

Dane: indeks WIG, dzienne logarytmiczne stopy zwrotu przemnożone przez 100

Okres: 2.01.1996-31.12.2016 (5258 obserwacji)

Źródło: stooq.pl

Początkowa wartość wektora parametrów: 10 losowych wartości z przedziałów $\mu \in (-1; 1)$, $\phi \in (0,9; 1)$, $\sigma_{\eta} \in (0,01; 1)$, $\sigma_v \in (0,01; 1)$, $G_0 \in (-0,5; 0,5)$, $\rho \in (-1,0)$.


Rozkład zaburzeń: $h_t(\theta | \varphi; \sigma)$ to wielowymiarowy rozkład normalny o wektorze wartości oczekiwanych φ i macierzy kowariancji $\sigma \Sigma$, gdzie Σ jest macierzą diagonalną.

Ciąg zaburzeń σ_m : ciąg geometryczny o ilorazie ½. Liczba cząsteczek: 1000. Liczba iteracji: 150.

Tablica 1. Otrzymane oszacowania parametrów.

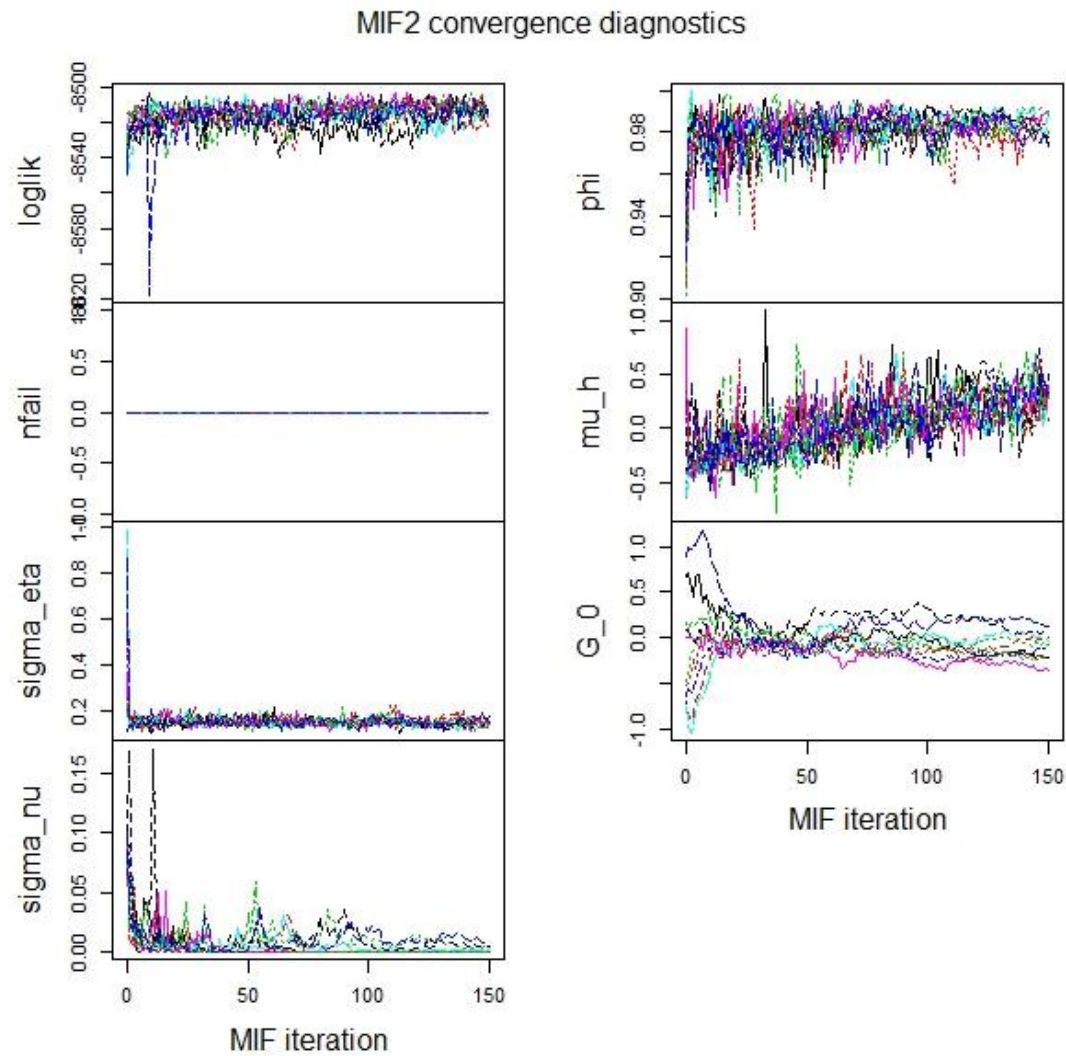
Model	μ	ϕ	σ_{η}	ρ	σ_v	lnL
Harvey i Shephard (1996)	0,4752	0,9841	0,1477	-0,247	-	-8511,579
Bretó (2014)	0,3641	0,9816	0,1591	-	0,0261	-8509,219

Źródło: opracowanie własne przy użyciu pakietów : pomp programu R Cran.

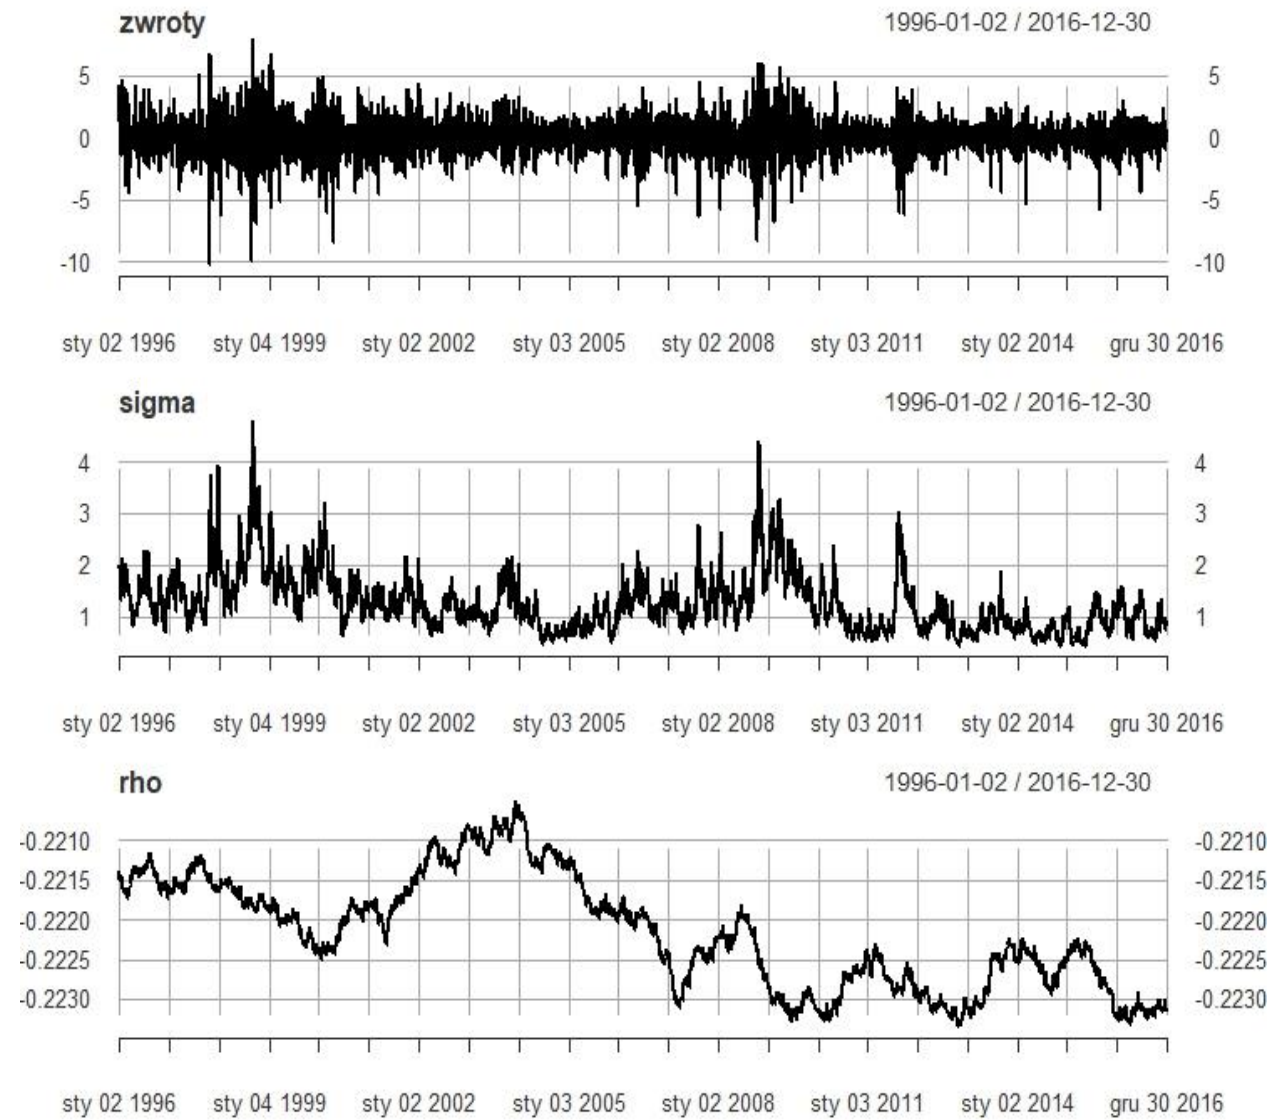


Rys. 6. Dienne notowania indeksu WIG w badanym okresie (a) oraz dienne logarytmiczne stopy zmian (b).


(a)



(b)



Rys. 7. (a) wykres diagnostycznych dla metody iterowanej filtracji oraz wykresy: stóp zmian (b góra), procesu zmienności (b środek), idiosynkratyczny „efekt dźwigni” (c dół).



Rys. 8. Jednowymiarowe profile funkcji wiarygodności wyznaczone za pomocą filtra cząsteczkowego (pozostałe parametry jak w optimum uzyskanym metodą iterowanego algorytmu) - linia czarna, lokalnie wygładzone wielomianami stopnia drugiego – linia niebieska.

Łódź, 14.05.2018

Dziękuję za uwagę



**WYDZIAŁ
EKONOMICZNO-SOCJOLOGICZNY**
Uniwersytet Łódzki



Literatura:

- Andrieu, C., Doucet, A., & Holenstein, R. (2010). Particle markov chain monte carlo methods. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 72(3), 269-342.
- Bandi, F. M., & Renò, R. (2012). Time-varying leverage effects. *Journal of Econometrics*, 169(1), 94-113.
- Black, F. (1976). Studies of Stock Price Volatility Changes. In: Proceedings of the 1976 Meeting of the Business and Economic Statistics Section, American Statistical Association, Washington DC, 177-181.
- Bretó, C. (2014). On idiosyncratic stochasticity of financial leverage effects. *Statistics & Probability Letters*, 91, 20-26.
- Brzozowska-Rup, K., & Dawidowicz, A. L. (2009). Metoda filtru cząsteczkowego. *Matematyka Stosowana: matematyka dla społeczeństwa*, 10(51), 69-107.
- Brzozowska-Rup, K., & Dawidowicz, A. L. (2011). Parameter estimation for nonlinear state-space models using particle methods combined with EM algorithm, FindEcon Monograph Series Advance in financial Market Analysis, Łódź University Press, 9.
- Carvalho, C., Johannes, M., Lopes, H., and Polson, N. (2008) Particle Learning and Smoothing. Discussion Paper 2008-32, Duke University Dept. of Statistical Science.
- Christie, A. A. (1982). The stochastic behavior of common stock variances: Value, leverage and interest rate effects. *Journal of financial Economics*, 10(4), 407-432.
- Crisan, D., & Doucet, A. (2002). A survey of convergence results on particle filtering methods for practitioners. *IEEE Transactions on signal processing*, 50(3), 736-746.
- Da-Silva, C. Q., Migon, H. S., & Correia, L. T. (2011). Dynamic Bayesian beta models. *Computational Statistics & Data Analysis*, 55(6), 2074-2089.
- Del Moral, P. (1996). Nonlinear filtering using random particles. *Theory of Probability & Its Applications*, 40(4), 690-701.
- Doucet, A., de Freitas, N., Gordon, N.J., (2001). Sequential Monte Carlo Methods in Practice. Springer-Verlag, New York.

- Fisher, R. A. (1915). Frequency distribution of the values of the correlation coefficient in samples from an indefinitely large population. *Biometrika*, 10(4), 507-521.
- Gilks, W. R., & Berzuini, C. (2001). Following a moving target—Monte Carlo inference for dynamic Bayesian models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 63(1), 127-146.
- Gordon, N., Salmond, D. and Smith, A. F. M. (1993). Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEE Proceedings-F*, 140, 107-13.
- Harvey, A., Ruiz, E., & Shephard, N. (1994). Multivariate stochastic variance models. *The Review of Economic Studies*, 61(2), 247-264.
- Harvey, A. C., & Shephard, N. (1996). Estimation of an asymmetric stochastic volatility model for asset returns. *Journal of Business & Economic Statistics*, 14(4), 429-434.
- Herbst, E., & Schorfheide, F. (2014). Sequential Monte Carlo sampling for DSGE models. *Journal of Applied Econometrics*, 29(7), 1073-1098.
- Ionides, E. L., Bhadra, A., Atchadé, Y., & King, A. (2011). Iterated filtering. *The Annals of Statistics*, 39(3), 1776-1802.
- Ionides, E. L., Nguyen, D., Atchadé, Y., Stoev, S., & King, A. A. (2015). Inference for dynamic and latent variable models via iterated, perturbed Bayes maps. *Proceedings of the National Academy of Sciences*, 112(3), 719-724.
- Jacquier, E., N. G. Polson and P. E. Rossi (1994). Bayesian analysis of stochastic volatility models. *Journal of Business and Economic Statistics* 12, 371-389.
- Kantas, N., Doucet, A., Singh, S. S., Maciejowski, J., & Chopin, N. (2015). On particle methods for parameter estimation in state-space models. *Statistical science*, 30(3), 328-351.
- Kastner, G., Frühwirth-Schnatter, S., & Lopes, H. F. (2014). Analysis of exchange rates via multivariate Bayesian factor stochastic volatility models. In *The Contribution of Young Researchers to Bayesian Statistics* (pp. 181-185). Springer, Cham.
- Kim, S., Shephard, N. and Chib, S. (1998). Stochastic Volatility: likelihood inference and comparison with ARCH models. *Review of Economic Studies*, 65, 361-93.
- Kim, J. (2005). *PARAMETER ESTIMATION IN STOCHASTIC VOLATILITY MODELS WITH MISSING DATA USING PARTICLE METHODS AND THE EMALGORITHM* (Doctoral dissertation, University of Pittsburgh). Dostęp online (27.04.2018): http://d-scholarship.pitt.edu/8265/1/JeongeunKim_2005.pdf

- Kitagawa, G. (1996). Monte Carlo filter and smoother for non-Gaussian nonlinear state space models. *Journal of Computational and Graphical Statistics*, 5, 1-25.
- Liu, J. S., & Chen, R. (1998). Sequential Monte Carlo methods for dynamic systems. *Journal of the American statistical association*, 93(443), 1032-1044.
- Liu, J. and West, M. (2001). Combined parameters and state estimation in simulation-based filtering. In: *Sequential Monte Carlo Methods in Practice* (by Doucet, A., J. F. G. De Freitas and N. Gordon) 97-233. Springer-Verlag, New York.
- Lopes, H. F., & Tsay, R. S. (2011). Particle filters and Bayesian inference in financial econometrics. *Journal of Forecasting*, 30(1), 168-209.
- Malik, S., & Pitt, M. K. (2011). Particle filters for continuous likelihood evaluation and maximisation. *Journal of Econometrics*, 165(2), 190-209.
- Melino, A., & Turnbull, S. M. (1990). Pricing foreign currency options with stochastic volatility. *Journal of econometrics*, 45(1-2), 239-265.
- Pajor, A. (2003). Procesy zmienności stochastycznej SV w bayesowskiej analizie finansowych szeregów czasowych. *Monografie: prace doktorskie/Akademia Ekonomiczna w Krakowie*, (2).
- Pitt, M.K., Shephard, N., (1999). Filtering via simulation: auxiliary particle filter. *Journal of the American Statistical Association* 94, 590–599.
- Ristic, B., Arulampalam, S., & Gordon, N. (2003). *Beyond the Kalman filter: Particle filters for tracking applications*. Artech house.
- Storvik, G. (2002). Particle filters for state-space models with the presence of unknown static parameters. *IEEE Transactions on signal Processing*, 50(2), 281-289.
- Suska, J. (2015). Modelling Leverage Effect in a Financial Time Series. *Zeszyty Naukowe Uniwersytetu Szczecińskiego. Finanse. Rynki finansowe. Ubezpieczenia*, (73 Ryzyko, zarządzanie, wartość), 843-852.
- Taylor, S. (1986). *Modelling financial time series*. Chichester: Wiley.
- Yu, J. (2005). On leverage in a stochastic volatility model. *Journal of Econometrics*, 127(2), 165-178.
- Veraart, A. E., & Veraart, L. A. (2012). Stochastic volatility and stochastic leverage. *Annals of Finance*, 8(2-3), 205-233.